

UNIVERSIDADE DE COIMBRA

Faculdade de Ciências e Tecnologia da Universidade de Coimbra



Lunar Lander

The evolution of Lunar Lander

Trabalho realizado no âmbito da edição de 2025/2026 da disciplina de Fundamentos De Inteligência Artificial da responsabilidade do docente Dinis Costa do Departamento de Engenharia Informática da Licenciatura em Engenharia Informática da Faculdade de Ciências e Tecnologias da Universidade de Coimbra.

José Amado, José Silva, Afonso Carvalho

Coimbra, 2025

Índice

1. Introdução

2. Mecanismos Evolutivos

- 2.1. Representação
- 2.2. Seleção
- 2.3. Cruzamento
- 2.4. Mutação
- 2.5. Função Objetivo

3. Experiências

- 3.1. Configuração Geral
- 3.2. Combinações Testadas
- 3.3. Procedimento de Avaliação

4. Resultados

- 4.1. Exemplo de Evolução
- 4.2. Ciclos das Experiências
- 4.3. Médias por Experiência

5. Análise

- 5.1. Impacto do Cruzamento
- 5.2. Impacto da Mutação
- 5.3. Correlação da Aptidão e Taxa de Sucesso
- 5.4. Testes de Significância
- 5.5. Limitações e Dificuldades

6. Adaptação ao Vento

- 6.1. Descrição do Problema
- 6.2. Análise Comparativa
- 6.3. Alterações ao Algoritmo
- 6.4. Resultados e Análise

7. Conclusões

8. Alteração no Código Fonte

1. Introdução

O presente relatório descreve o trabalho realizado no âmbito do Trabalho Prático N°2 da unidade curricular de Fundamentos de Inteligência Artificial. O objetivo é o desenvolvimento de um algoritmo de neuroevolução capaz de evoluir controladores para o problema do Lunar Lander, tanto em condições sem vento como na presença de vento. A abordagem utilizada neste trabalho é a neuroevolução: em vez de treinar a rede neuronal por gradiente descendente, os pesos da rede são tratados como um genótipo e otimizados por um algoritmo evolutivo. Cada indivíduo da população representa uma rede neuronal completa, e a sua aptidão é avaliada simulando episódios no ambiente.

O trabalho foi realizado pelos seguintes alunos:

Nome	Nº Estudante	Email	Turma
José Amado	2023212241	Uc2023212241@student.uc.pt	10
José Silva	2023215540	Uc2023215540@student.uc.pt	10
Afonso Carvalho	2023211750	Uc2023211750@student.uc.pt	10

2. Mecanismos Evolutivos

2.1. Representação

Cada indivíduo é representado por um genótipo, uma lista de números reais correspondente aos pesos de uma rede neuronal totalmente ligada. A arquitectura usada foi (8, 12, 2): 8 neurónios de entrada correspondentes às 8 observações do ambiente, uma camada oculta com 12 neurónios e 2 neurónios de saída com os comandos dos motores. Com estes valores o genótipo tem 120 genes ou pesos que são inicializados com valores amostrados uniformemente no intervalo $[-1, 1]$.

2.2. Seleção de Progenitores

Foi utilizada seleção por torneio (tournament selection). Em cada operação de seleção, são amostrados aleatoriamente 5 indivíduos da população, sendo selecionado como progenitor aquele com maior aptidão. Esta escolha justifica-se por duas razões principais.

Em primeiro lugar, a seleção por torneio apresenta maior robustez em populações com aptidões negativas ou ruidosas, ao contrário da seleção por roleta, que requer normalização e pode tornar-se instável quando existem valores negativos ou distribuições pouco diferenciadas, como é comum nas fases iniciais da evolução.

Em segundo lugar, a pressão seletiva é facilmente controlada através do tamanho do torneio. A utilização de subconjuntos de 5 indivíduos permite estabelecer uma pressão moderada, equilibrando a exploração do espaço de soluções com a manutenção de diversidade populacional.

2.3. Cruzamento

O mecanismo de cruzamento utilizado é o uniforme (uniform crossover). Para cada par de progenitores, cada gene do descendente é herdado do pai ou da mãe com probabilidades iguais, de forma independente para cada posição do genótipo. Esta escolha justifica-se pela natureza contínua e de alta dimensionalidade do genótipo (120 pesos). O cruzamento uniforme promove uma mistura granular dos genótipos, permitindo explorar combinações mais diversas de pesos e evitando a perda prematura de diversidade populacional.

Ao contrário do cruzamento aritmético, também considerado, que combina os progenitores através de uma média ponderada dos seus genes, o cruzamento uniforme seleciona cada gene independentemente de um dos pais. Esta diferença é relevante no contexto de otimização contínua, pois o cruzamento aritmético tende a reduzir a variância da população ao aproximar os indivíduos da média, o que pode conduzir à convergência precoce para soluções subótimas.

2.4. Mutação

O operador de mutação utilizado é a mutação uniforme (uniform mutation). Cada gene de um genótipo, tendo em conta a probabilidade definida, é sujeito a uma mutação, sendo a cada um adicionado um valor amostrado uniformemente no intervalo $[-\delta, \delta]$, com $\delta=0.1$.

Esta escolha justifica-se pela natureza contínua do espaço de procura, onde pequenas perturbações nos pesos permitem ajustar gradualmente o comportamento. Ao contrário da mutação gaussiana, também considerada, que concentra a maioria das alterações em torno de valores muito próximos de zero, a mutação uniforme distribui as perturbações de forma equitativa dentro de um intervalo definido, promovendo uma exploração mais consistente do espaço de soluções.

Métodos de mutação ao nível dos *bits* não foram utilizados por não se adequarem a problemas contínuos. Estas abordagens podem introduzir alterações imprevisíveis nos valores dos pesos, destruindo a relação de proximidade no espaço de soluções e dificultando a convergência.

Adicionalmente, a mutação é aplicada apenas a um subconjunto reduzido de genes, permitindo alterações locais sem comprometer a estrutura global do indivíduo, o que contribui para um equilíbrio entre exploração e estabilidade.

2.5. Função Objetivo

A função objetivo foi desenhada com base nas regras do nosso controlador reativo do TP1, combinando duas componentes: uma pontuação de trajetória, calculada ao longo de todos os passos do episódio e normalizada pelo número de passos, e uma pontuação terminal, calculada com base no estado final da nave. A aptidão final resulta da soma das componentes de trajetória e terminal. Não existindo um limite superior teórico fixo, a função foi calibrada de forma que soluções ótimas, correspondentes a aterragem bem-sucedida e comportamento estável, conduzam a valores próximos de 100.

Pontuação de trajetória: por passo de simulação, normalizadas pelo número de passos:

- Desvio horizontal: $-0.35 \cdot |x|$
- Altitude: $-0.10 \cdot y$

- Velocidade horizontal: $-0.10 \cdot |vx|$
- Erro de orientação: $-0.30 \cdot |\sigma|$, onde $\sigma = (\theta - \theta_{alvo}) + v\theta$
- Descida rápida: $-1.00 \cdot descent_error$ se altitude baixa ou $vy < -0.2$, caso contrário $-0.35 \cdot descent_error$
- Contacto com o solo: $+0.50$ por cada perna em contacto

O θ_{alvo} é calculado com base na posição futura prevista $x + vx$, incentivando a nave a inclinar-se em direcção ao centro da plataforma.

Pontuação terminal: calculada com base no estado final da nave:

- Posição horizontal: $-12 \cdot |x|$
- Altitude: $-6 \cdot |y|$
- Velocidade horizontal: $-5 \cdot |vx|$
- Descida rápida: $-14 \cdot \max(0, -vy - 0.2)$
- Orientação: $-8 \cdot |\theta|$
- Velocidade angular: $-3 \cdot |v\theta|$
- Aterragem bem-sucedida: $+100$
- Colisão sem sucesso ($y \leq 0.05$): -50

3. Experiências

3.1. Configuração Geral

As experiências têm como objetivo estudar o impacto da probabilidade de mutação, probabilidade de cruzamento e uso de elitismo no desempenho do algoritmo evolutivo. Os restantes parâmetros são fixos em todas as experiências, conforme apresentado na tabela seguinte:

Parâmetro	Valor
Tamanho da população	100

Parâmetro	Valor
Número de gerações	100
Arquitetura da rede neuronal	(8, 12, 2)
Tipo de seleção de progenitores	Torneio ($k=5$)
Tipo de crossover	Uniforme ($p=0.5$ por gene)
Tipo de mutação	Uniforme ($\delta=0.1$)
Seeds utilizadas	963, 952, 364, 912, 140

3.2. Combinações Testadas

Foram realizadas 8 experiências com 5 execuções independentes cada, totalizando 40 ciclos evolutivos. As combinações de parâmetros testadas, sendo as recomendadas, encontram-se na tabela seguinte:

Experiência	Mutação	Crossover	Elitismo
1	0.008	0.5	0
2	0.05	0.5	0
3	0.008	0.9	0
4	0.05	0.9	0
5	0.008	0.5	1
6	0.05	0.5	1
7	0.008	0.9	1
8	0.05	0.9	1


3.3. Procedimento de Avaliação

Após cada ciclo evolutivo, o melhor indivíduo de cada foi testado em 1000 episódios independentes do ambiente. Para cada indivíduo foram registrados a aptidão média e a taxa de sucesso de aterragem ao longo desses 1000 episódios. Estes valores são registrados e são a base de toda a análise comparativa entre experiências.

4. Resultados

4.1. Exemplo de Evolução

A figura seguinte apresenta a evolução da aptidão média e da taxa de sucesso ao longo de 100 gerações. Esta representação permite observar o progresso do algoritmo evolutivo tanto em termos de qualidade das soluções encontradas como da sua capacidade de realizar aterragens bem-sucedidas, evidenciando tendências de melhoria e eventuais fases de estagnação durante o processo de otimização:



Numa análise qualitativa, observa-se que nas gerações iniciais os agentes apresentam comportamentos instáveis e pouco coordenados, resultando frequentemente em trajetórias descontroladas. Com a evolução, começam a surgir estratégias mais estruturadas, como a correção da posição horizontal e um melhor controlo da orientação e da velocidade de descida.


Nas gerações mais avançadas, os comportamentos tornam-se mais consistentes, com aproximações ao solo mais controladas e maior frequência de contactos estáveis. Ainda assim, persistem situações de quase-sucesso, indicando dificuldades na afinação fina e alguma estagnação do processo evolutivo.

4.2. Ciclos das Experiências

Os resultados completos das 40 avaliações encontram-se na tabela seguinte. Cada célula apresenta a aptidão média e a taxa de sucesso de aterragem obtidos nos 1000 episódios de teste do melhor indivíduo desse ciclo (aptidão / taxa de sucesso). Tenha em atenção que a aptidão tende para 100.


Exp.	Run 0	Run 1	Run 2	Run 3	Run 4
1	-9.42 / 0.048	-3.22 / 0.261	-12.47 / 0.067	-36.95 / 0.017	-36.18 / 0.044
2	-30.09 / 0.062	-27.97 / 0.218	-35.69 / 0.091	-29.88 / 0.127	62.52 / 0.764
3	53.58 / 0.696	96.35 / 0.976	88.37 / 0.908	92.42 / 0.954	-11.26 / 0.020
4	67.88 / 0.790	20.98 / 0.514	75.15 / 0.835	92.69 / 0.957	-25.88 / 0.202
5	-7.32 / 0.098	-23.70 / 0.085	-28.59 / 0.030	-27.28 / 0.030	-17.61 / 0.128
6	-6.76 / 0.001	-28.59 / 0.192	-18.95 / 0.033	87.70 / 0.923	56.50 / 0.721
7	47.60 / 0.681	95.45 / 0.975	51.96 / 0.665	88.77 / 0.931	17.47 / 0.462
8	93.91 / 0.963	78.54 / 0.875	72.76 / 0.816	81.30 / 0.888	82.75 / 0.866

A figura seguinte apresenta a correlação entre o valor da função objetivo e a taxa de sucesso das aterragens ao longo das gerações. Observa-se uma correlação positiva, indicando que indivíduos com maior aptidão tendem a apresentar melhores desempenhos na tarefa:



Este resultado é expectável, uma vez que a função objetivo incorpora critérios semelhantes aos utilizados na verificação de aterragem bem-sucedida, o que contribui para alinhar o valores.

A figura seguinte apresenta um box plot da distribuição da aptidão e sucesso em cada experiência:




4.3. Médias por Experiência

A tabela seguinte resume as médias de aptidão e taxa de sucesso de aterragem por experiência, calculadas sobre os 5 ciclos:

Exp.	Mutação	Crossover	Elite	Sucesso médio	Aptidão Média
1	0.008	0.5	0	0.087	-19.65
2	0.05	0.5	0	0.252	-12.22
3	0.008	0.9	0	0.711	63.89
4	0.05	0.9	0	0.660	46.16
5	0.008	0.5	1	0.074	-20.90
6	0.05	0.5	1	0.374	17.98
7	0.008	0.9	1	0.743	60.25
8	0.05	0.9	1	0.882	81.85

A figura seguinte apresenta um heatmap das médias de sucesso obtidas em cada experiência com o melhor indivíduo de cada:



5. Análise e Discussão

5.1. Impacto do Cruzamento

A diferença mais marcante nos resultados é introduzida pela probabilidade de cruzamento. As experiências com $crossover=0.9$ apresentam consistentemente taxas de sucesso muito superiores às com $crossover=0.5$, independentemente dos outros parâmetros. Por exemplo, comparando as experiências 1 e 3, que são idênticas excepto no cruzamento, a taxa de sucesso média passa de 0.262 para 0.727. O mesmo padrão é visível entre as experiências 5 e 7 (0.301 vs. 0.838).

Uma probabilidade de cruzamento elevada significa que a maioria dos descendentes resulta da combinação de dois progenitores. Dado que o cruzamento uniforme mistura genes de forma granular, um cruzamento mais frequente aumenta a capacidade do algoritmo de combinar boas parcialidades de diferentes indivíduos, acelerando a convergência para soluções de alta qualidade.

5.2. Impacto da Mutação

O impacto da taxa de mutação é também relevante. Nas experiências com $mutation=0.008$, os resultados tendem a ser inferiores ou mais inconsistentes, especialmente nos cenários com menor diversidade genética, obtendo-se valores de 0.09 e 0.07 nos casos menos favoráveis. Já com $mutation=0.05$ observa-se uma melhoria clara e consistente na maioria das experiências, atingindo inclusivamente o melhor resultado global (0.88). Estes resultados sugerem que uma taxa de mutação mais elevada permite aumentar a diversidade da população e reduzir o risco de estagnação prematura durante o processo evolutivo.

É de notar que uma taxa de mutação de 0.008 implica que, em média, apenas 0.8% dos genes sofrem mutação por genótipo, o que pode resultar em pouca exploração do espaço de soluções. Por outro lado, uma taxa de mutação superior mostrou-se mais eficaz na introdução de diversidade genética e na capacidade de adaptação da população. É de notar que se fosse utilizado um mecanismo de mutação diferente o impacto poderia ser bastante diferente.

5.3. Impacto do Elitismo

O elitismo tem efeito positivo claro quando combinado com cruzamento elevado: as experiências 7 e 8 superam as experiências 3 e 4 em taxa de sucesso média. Com cruzamento baixo (experiências 5 e 6 vs. 1 e 2), o elitismo não traz benefício consistente e pode agravar a variância dos resultados.

Este comportamento é esperado: o elitismo garante que o melhor indivíduo encontrado não se perde nas transições entre gerações, mas não resolve o problema de exploração insuficiente quando o cruzamento é fraco.

5.4. Correlação da Aptidão e Taxa de Sucesso

A análise de correlação de Pearson entre a aptidão média obtida nos 1000 episódios de teste e a taxa de sucesso de aterragem revela uma correlação positiva forte ($r \approx 0.90$). Isto confirma que a função objetivo desenhada é um bom aproximamento para o desempenho real do agente. A ausência de correlação perfeita reflete que a aptidão incorpora também informação sobre a qualidade da trajetória, suavidade, orientação, velocidade, que não está completamente capturada pela taxa de sucesso binária.

5.5. Testes de Significância

O teste de normalidade de Shapiro-Wilk sobre as taxas de sucesso de cada experiência revelou que em vários grupos a distribuição não pode ser considerada normal ($p < 0.05$). As comparações entre grupos foram realizadas com o teste não-paramétrico de Mann-Whitney:

- Elitismo 0 vs. 1: diferença significativa ($p < 0.05$) a favor do elitismo quando o crossover é alto.
- Mutação 0.008 vs. 0.05: diferença não significativa ($p > 0.05$) em termos globais.
- Cruzamento 0.5 vs. 0.9: diferença altamente significativa ($p < 0.01$), sendo a maior fonte de variação nos resultados.

Segue a tabela dos testes de normalidade (Shapiro-Wilk):

Exp.	W	p-value	Normalidade
1	0.722	0.016	Não normal
2	0.725	0.017	Não normal
3	0.754	0.032	Não normal
4	0.915	0.497	Normal
5	0.888	0.349	Normal
6	0.854	0.207	Normal
7	0.922	0.542	Normal
8	0.943	0.685	Normal

Segue a tabelas dos testes de Mann-Whitney:

Comparação	U	p-value	Conclusão
Elite=0 vs. Elite=1	182.000	0.636	Não significativo
Mutação 0.008 vs. 0.05	159.000	0.273	Não significativo
Cruzamento 0.5 vs. 0.9	45.000	< 0.001	Significativo

5.6. Limitações e Dificuldades

- **Variância elevada:** com apenas 5 ciclos por experiência, alguns ciclos da mesma configuração apresentam taxas muito diferentes. Mais ciclos tornariam as conclusões mais robustas.
- **Avaliação estocástica:** a aptidão é calculada a partir de um único episódio por indivíduo por geração, introduzindo ruído. Avaliar em múltiplos episódios reduziria este ruído, a custo computacional mais elevado.
- **Convergência prematura:** em vários ciclos com cruzamento baixo, a população converge para soluções subótimas sem recuperação. Mecanismos de manutenção de diversidade poderiam mitigar este problema.

6. Evolução com Vento


6.1. Descrição do Problema

Ao incluir vento, a tarefa de aterragem torna-se consideravelmente mais difícil. O vento introduz perturbações na nave que não são diretamente observáveis pelo agente. Para analisar as capacidades evolutivas deste sistema foi ativado o vento com intensidade: $wind_power = 15$.


6.2. Análise Comparativa

A presença de vento reduz a taxa de sucesso dos melhores indivíduos anteriores quando testados no novo ambiente, confirmando que as políticas aprendidas sem vento não generalizam diretamente. Os agentes evoluídos com vento devem aprender políticas mais conservadoras, manter velocidade de descida mais baixa e margem de orientação maior, para compensar as perturbações inesperadas.

Para fins comparativos foram inicialmente testados os indivíduos evoluídos sem a presença de vento num ambiente com vento. Segue o gráfico que regista a aptidão e sucesso médios dos indivíduos neste contexto:



De seguida foram evoluídos indivíduos num ambiente com presença de vento, de modo a permitir a sua adaptação ao contexto que posteriormente serão testados. Segue o gráfico que regista a aptidão e sucesso médios dos indivíduos neste contexto:



Curiosamente, os resultados não são totalmente consistentes entre configurações, mas observa-se que indivíduos evoluídos sem vento conseguem, em vários casos, atingir taxas de sucesso comparáveis ou até superiores quando testados em ambiente com vento.

Este comportamento pode ser explicado pelo facto de, num ambiente sem vento, os agentes aprenderem estratégias de controlo mais generalizáveis, focadas na gestão da orientação e da velocidade, que continuam eficazes

mesmo na presença de perturbações. Por outro lado, os agentes evoluídos com vento tendem a adaptar-se a padrões específicos das forças aplicadas durante o treino, o que pode levar a algum *overfitting* às condições particulares desse ambiente. Como consequência, o seu desempenho pode não generalizar tão bem, mesmo quando testados em cenários aparentemente semelhantes.

6.3. Alterações no Algoritmo

Numa fase inicial, foram exploradas alterações nos parâmetros dos mecanismos evolutivos, nomeadamente na probabilidade de mutação, probabilidade de cruzamento e configuração da seleção. Estas modificações não produziram melhorias consistentes no desempenho, mantendo-se taxas de sucesso semelhantes às observadas anteriormente.


De seguida, foram testadas alterações ao próprio tipo de operadores utilizados. Em particular, substituiu-se o cruzamento uniforme por cruzamento aritmético e a mutação uniforme por mutação gaussiana. No entanto, estas abordagens também não resultaram em ganhos, sugerindo que a limitação não se encontrava nos operadores evolutivos em si.

Posteriormente, foi considerada a reformulação da função objetivo. Ainda assim, verificou-se que a função já utilizada não constituía um fator limitante, uma vez que apresenta boa correlação com o sucesso da aterragem e captura adequadamente os critérios relevantes da tarefa. Alterações nesta componente não conduziram a melhorias.

Por fim, a alteração que demonstrou impacto positivo foi o aumento da capacidade da rede neuronal, passando de 12 para 36 neurónios na camada oculta. Este aumento permitiu ao modelo representar políticas de controlo mais complexas, melhorando a adaptação às perturbações introduzidas pelo vento e resultando em desempenhos superiores.

6.4. Resultados e Análise

A figura seguinte apresenta um heatmap com as médias da taxa de sucesso obtidas nas diferentes configurações testadas em ambiente com vento:



Observa-se que com maior capacidade da rede neuronal (36 neurónios na camada oculta) todos os cenários apresentam melhores resultados na taxa média de sucesso. Este comportamento confirma que, neste contexto, a limitação principal não se encontrava nos mecanismos evolutivos nem na função objetivo, mas sim na capacidade representacional do modelo.

Verifica-se assim uma melhoria na capacidade de generalização dos agentes, que passam a lidar melhor com as perturbações introduzidas pelo vento, mantendo comportamentos estáveis em diferentes situações. Isto sugere que a rede com maior dimensão consegue aprender políticas menos específicas e mais robustas.

Globalmente, os resultados indicam que, em ambientes mais complexos e com perturbações externas como o vento, a capacidade do modelo em representar estratégias de controlo mais sofisticadas torna-se crítica para o sucesso da aprendizagem evolutiva.

7. Conclusões

Este trabalho demonstrou a viabilidade da neuroevolução como abordagem para o problema do Lunar Lander. O algoritmo evolutivo implementado, com seleção por torneio, cruzamento uniforme e mutação uniforme, consegue evoluir agentes capazes de aterrar a nave com taxas de sucesso superiores a 95% sem vento e 90% com vento nas configurações optimais.

Os principais resultados e aprendizagens são os seguintes: o cruzamento é o fator mais determinante no desempenho, o elitismo contribui positivamente para a estabilidade quando combinado com exploração adequada, a função objetivo desenhada estima o desempenho real e a variância entre ciclos é elevada, sublinhando a importância de múltiplas repetições para conclusões fiáveis.

8. Alterações no Código Fonte

Para além das implementações pedidas no enunciado, foram realizadas algumas modificações ao código base com o objetivo de melhorar a organização experimental e a análise de resultados.

Em particular, foi desenvolvida uma pipeline para a execução sistemática de testes, de modo a permitir automatizar múltiplas execuções com diferentes configurações, bem como facilitar a recolha consistente de métricas ao longo das gerações.

Adicionalmente, foi alterado o formato dos ficheiros de log e o respetivo mecanismo de leitura, de forma a registar informação mais detalhada sobre o processo evolutivo. Para além dos valores individuais, passaram a ser armazenadas métricas agregadas por geração, nomeadamente a aptidão média da população e a taxa de sucesso média. Estas alterações permitiram uma análise mais completa do comportamento do algoritmo ao longo do tempo, suportando a construção dos gráficos e comparações dadas neste relatório.